



基于机器学习的虚拟化网络故障诊断 系统的研究与实现

报告人：张欢欢

日期：2019年5月14日

在线版：

内容提纲



- 研究背景
- 研究目标
- 研究成果
- 原型系统
- 总结展望

内容提纲



- 研究背景

- 研究目标

- 研究成果

- 原型系统

- 总结展望

数据中心网络



□ **数据中心**：数据中心的计算、存储以及内存**资源以网络相连形成海量资源池**，为应用程序提供按需服务

计算——分布式计算框架



网络是数据中心提供海量资源的核心

存储——分布式文件系统



网络基础设施



内存——分布式缓存系统



数据中心网络故障





□ 斯坦福大学数据中心网络故障统计报告



快速、精确的数据中心网络故障诊断至关重要

□ Ponemon机构对数据中心故障引起的经济损失的研究



网络故障造成大量的经济损失

数据中心网络故障诊断



网络故障诊断流程

信息采集：

- 基于网络设备的信息采集
 - 报文抽样、报文镜像
- 基于终端的信息采集
 - TCP性能指标统计、报文探测



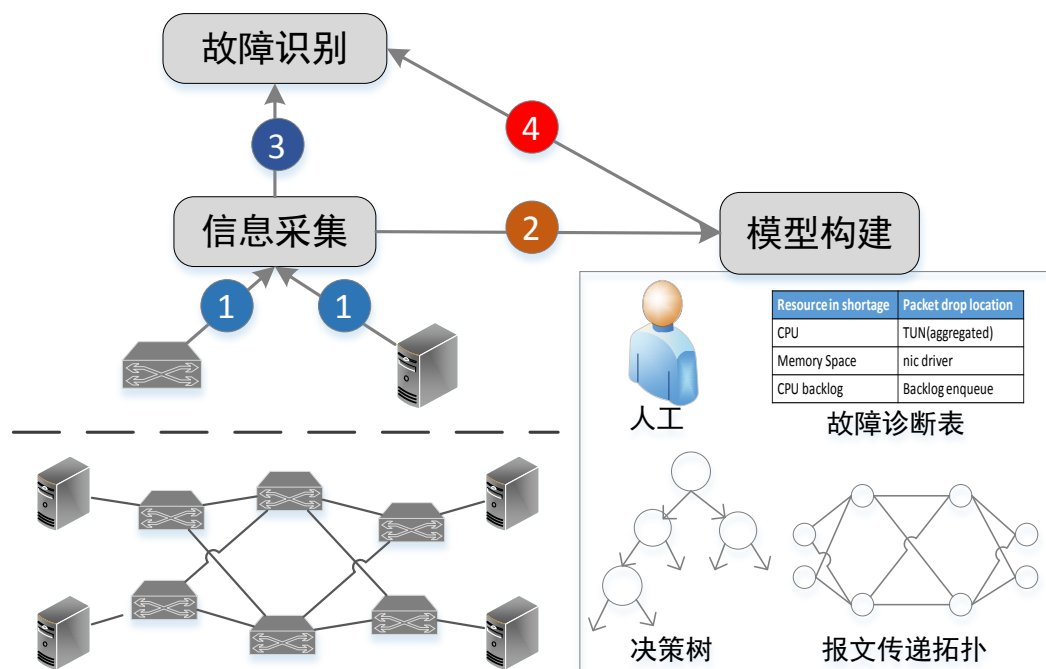
模型构建：

- 基于报文路径的建模方法
 - 可达性故障
- 基于机器学习的建模方法
 - 可达性与性能故障



故障识别：

- 结合信息采集与模型，实现对数据中心的实时监控



数据中心网络故障诊断




故障识别流程

故障识别步骤：

- 信息采集器**采集**网络信息
- 数据传输**到故障诊断服务器
- 使用模型进行**故障诊断**

采集开销


诊断精度



细粒度的信息采集与精确的故障诊断模型共同决定了故障诊断系统的高精度故障定位与诊断，但是细粒度的信息采集会带来巨大的采集开销，数据中心网络故障诊断主要关注**诊断开销**与**诊断精度**问题

诊断精度：

- 故障表征相似
- 数据规模小、质量低



采集开销

- 降低传输数据量

- 抽样采集
- 周期性上传

- 降低数据规模
- 损失数据精度

诊断精度

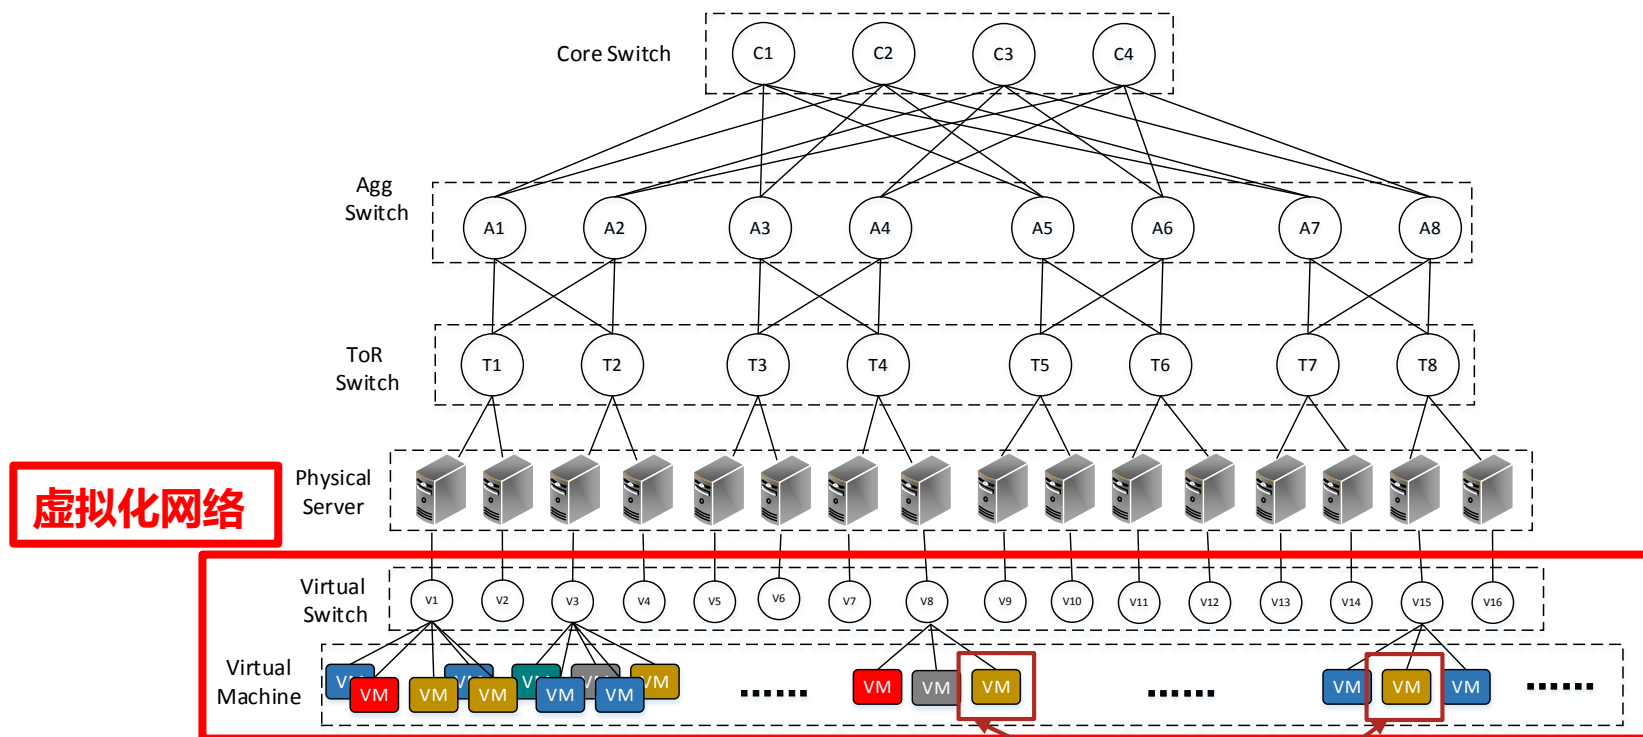
- 细粒度采集数据
- 构建精确的模型

数据中心虚拟化网络



虚拟化网络架构

定义：对传统网络的抽象，用户在共享的物理网络中定制私有虚拟网络

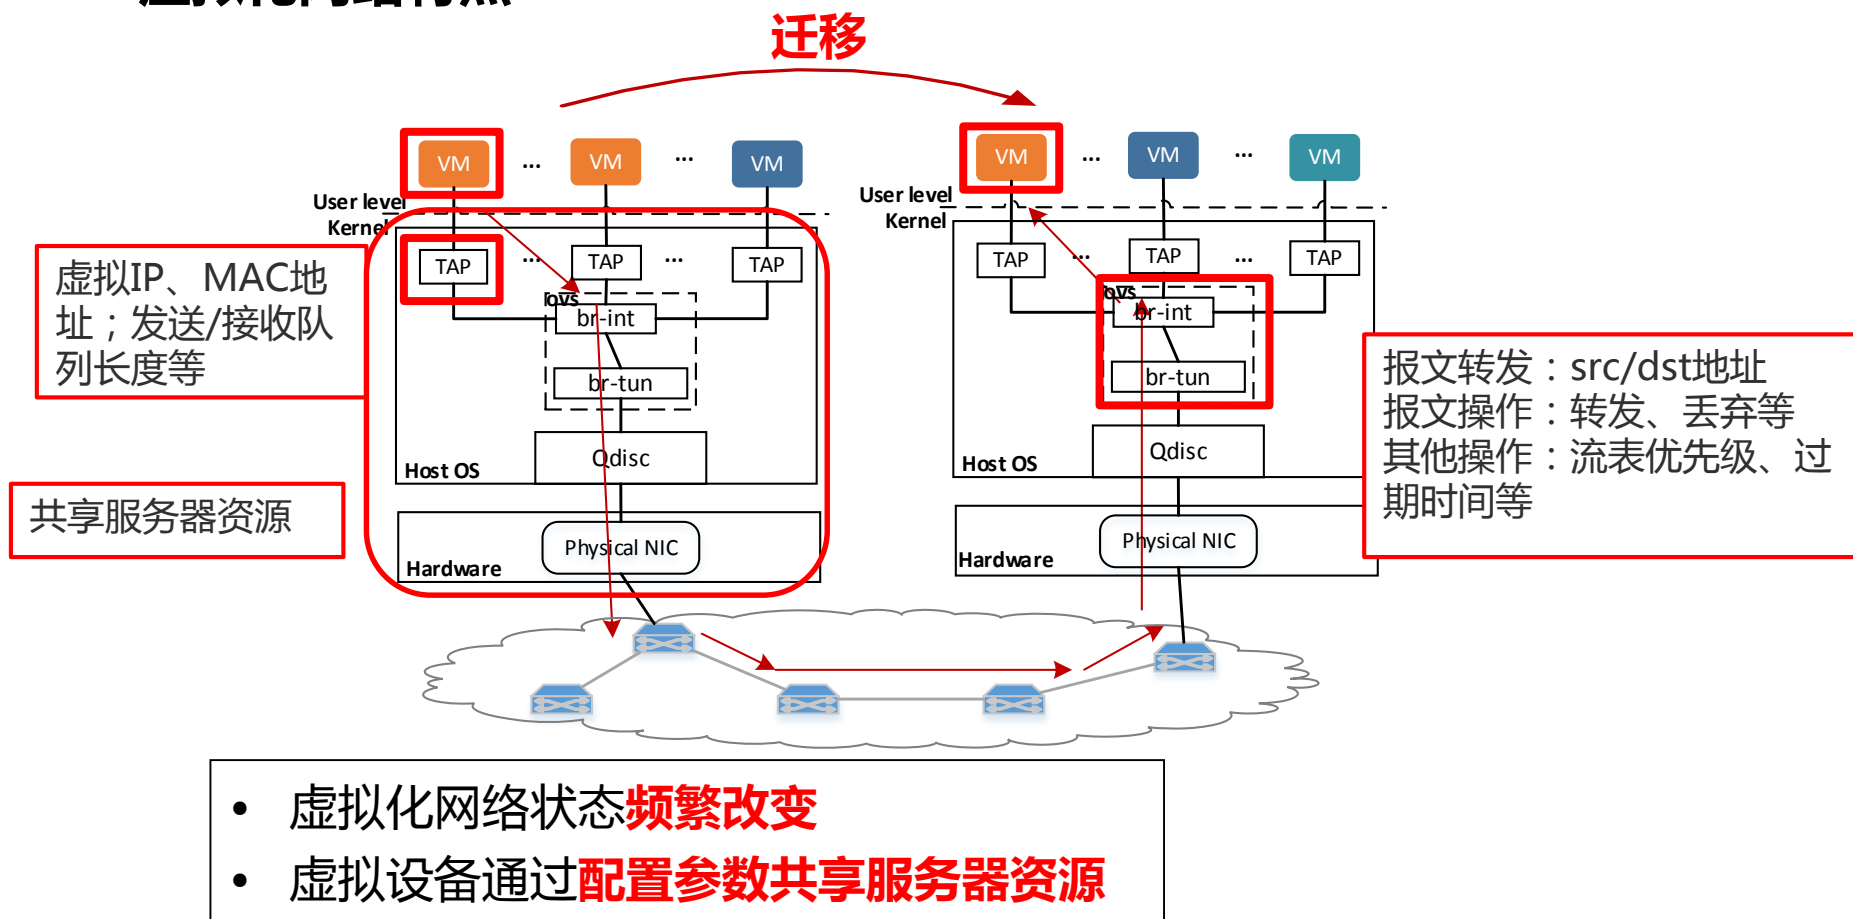


虚拟化网络存在于所有的物理机中

同一租户的虚拟机部署在不同的物理机中

数据中心虚拟化网络

□虚拟化网络特点





现有研究工作存在的问题与挑战

集中式故障诊断导致信息采集开销大

□虚拟化网络故障特点

- 网络状态频繁改变
- 虚拟设备参数配置

网络故障频率高


表征相似的故障

虚拟机迁移为例：

- CPU、内存、磁盘使用率
- 每秒可能迁移几千台虚拟机[1]

虚拟化网络中存在大量暂时性故障以及表征相似的故障，降低数据采集规模与数据质量带来的精度损失较大，现有的信息采集方法难以在**不影响故障诊断精度**的前提下**降低信息采集开销**。

Outgoing Bandwidth	Backlog Enqueue
pCPU Backlog	Backlog Enqueue
VM Bottleneck (CPU or Bandwidth)	TUN (individual)



- 抽样采集：难以感知虚拟化网络状态变化
- 周期性上传：降低了数据精度

- 暂时性故障
- 表征相似的故障


诊断精度低

[1]Kazemian P, Chang M, Zeng H, et al. Real time network policy checking using header space analysis[C]. NSDI 2013

现有研究工作存在的问题与挑战

表征相似故障导致故障诊断精度低


□ 虚拟化网络故障诊断需求



• 精确的故障定位与诊断

- 识别故障类型
- 定位故障位置

虚拟化网络故障诊断模型需要在信息采集开销与故障诊断精度之间做出权衡，而虚拟化网络中存在大量表征相似的故障，现有的建模方法难以在**低信息采集开销**下，**提高故障诊断精度**



➢ 基于机器学习的建模方法

- 故障诊断范围有限
- 故障诊断精度低

□ 解决办法

- 细粒度采集数据信息
- 设计不同的故障诊断模型

- 信息采集开销大且实现成本高
- 难以构建合理的故障诊断模型

[1]Arzani B, Ciraci S, Loo B T, et al. Taking the blame game out of data centers operations with netpoirot. SIGCOMM 2016.

研究现状——信息采集



□ 典型文献

- I Know What Your Packet Did Last Hop: Using Packet Histories to Troubleshoot Networks. NSDI, 2014.
- Packet-level telemetry in large datacenter networks. SIGCOMM, 2015.
- Taking the Blame Game out of Data Centers Operations with NetPoirot. SIGCOMM, 2016.
- 007: Democratically Finding the Cause of Packet Drops. NSDI, 2018.

□ 存在问题

- 抽样采集方法可以实现对网络状态的整体评估，但是难以感知暂时性故障
- 周期性上传方法将采集的信息进行压缩后上传，降低了数据传输量，但损失了数据精度
- 虚拟化网络中存在大量表征相似的故障以及暂时性故障，降低数据精度与规模对虚拟化网络故障诊断精度影响大

研究现状——模型构建



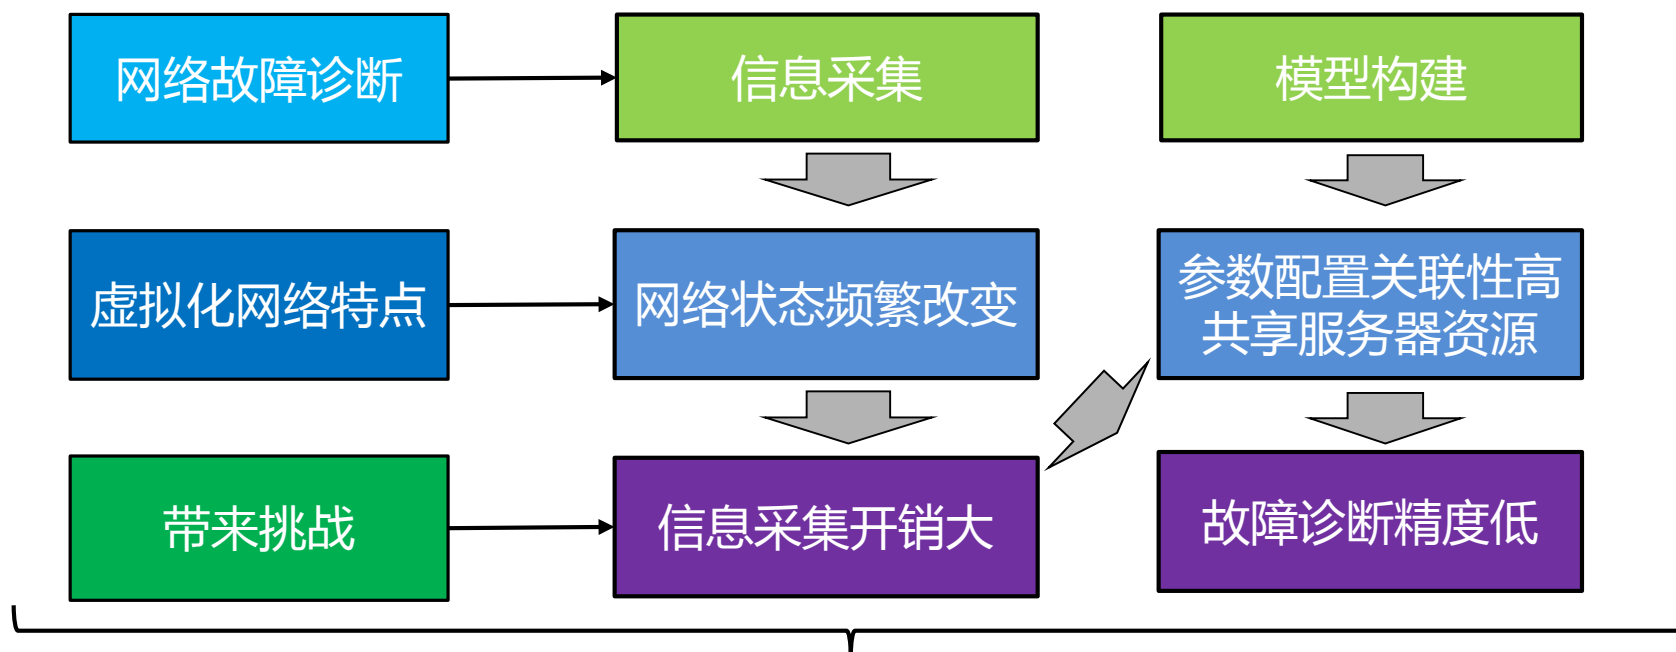
□ 典型文献

- Header Space Analysis: Static Checking For Networks. NSDI, 2012.
- Simplifying Datacenter Network Debugging with PathDump. OSDI, 2016.
- Taking the Blame Game out of Data Centers Operations with NetPoirot. SIGCOMM, 2016.
- Distributed network monitoring and debugging with switchpointer. NSDI, 2018.

□ 存在问题

- 基于报文传输路径的模型存在信息采集开销大、实现成本高且故障诊断范围有限的问题，难以用于诊断性能故障
- 基于机器学习方法构建的分类模型由于训练数据存在数据不完备、数据质量低的问题，导致模型的精度难以提高
- 虚拟化网络中存在大量表征相似的故障，现有的模型无法有效诊断这类故障

数据中心虚拟化网络带来的挑战




- 现有研究工作主要关注传统网络故障诊断，应用于虚拟化网络故障诊断导致信息采集开销大、故障诊断精度低
- 需要研究一种低开销、高精度的虚拟化网络故障诊断系统


虚拟化网络故障诊断研究思路




信息采集阶段



模型构建阶段



故障识别阶段




虚拟化网络故障属于小概率事件

故障感知

在信息采集过程中识别网络异常，过滤正常网络状态信息，减少传输的数据量，降低信息采集开销。

模型构建

将诊断结果在环境中进行验证，并根据结果调整模型，学习不同故障状态下各种故障解决方案的正确性，精确诊断虚拟化网络故障。



将信息采集与故障诊断模型相结合，实现对虚拟化网络的实时监控

内容提纲



■ 研究背景


■ 研究目标

■ 研究成果

■ 原型系统

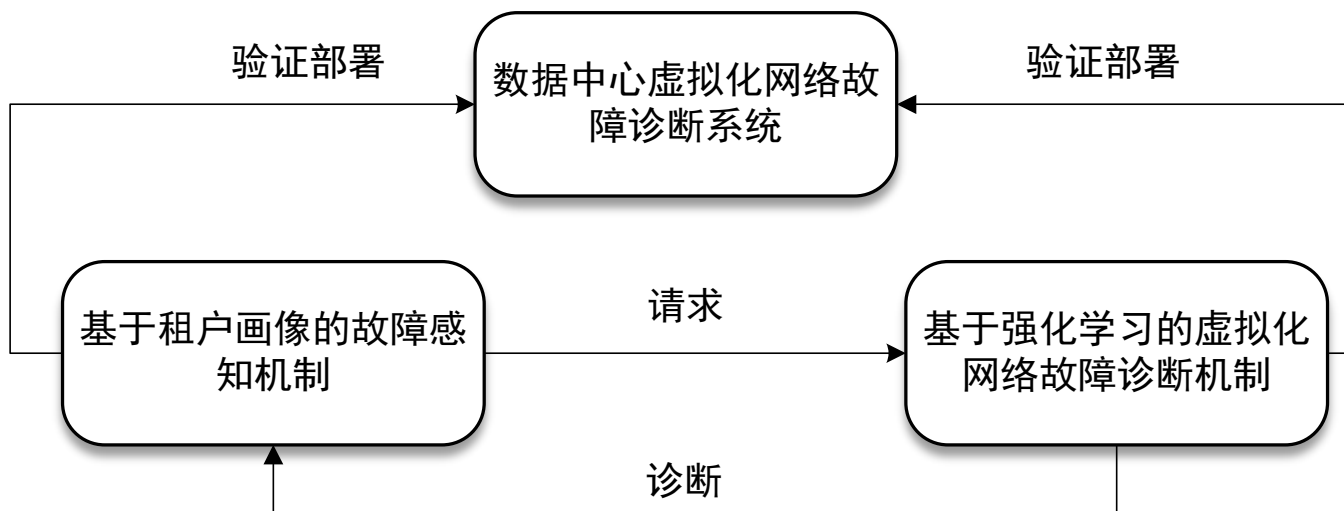
■ 总结展望

研究目标



- 本所论论文针对信息采集和模型构建两个关键技术，提出相关的机制和算法，实现**低开销、高精度**的虚拟化网络故障诊断。
- 在信息采集阶段，根据虚拟化网络故障特点、产生原因，采集充足的信息刻画虚拟机网络通信画像，并利用机器学习方法分析画像特征，构建**基于租户画像的故障感知模型**，在信息采集过程中过滤正常网络状态信息，降低信息采集开销。
- 在模型构建阶段：根据强化学习算法建模要求设计网络状态空间、动作集合、奖励函数等，通过使用信息增益方法划分存在多个故障的网络状态，提高网络状态空间划分纯度，最后**构建基于Q-learning的虚拟化网络故障诊断模型**，实现对表征相似故障的精确诊断，提高虚拟化网络故障诊断精度。
- 在东南大学云计算中心实际环境，结合相关理论研究成果，设计、开发与部署基于机器学习的虚拟化网络故障诊断系统。，验证本文的理论成果。

内容提纲



- 研究**基于信息增益的网络状态空间划分方法**，提高网络状态划分纯度
 - 研究**基于Q-learning的虚拟化网络故障诊断方法**，精确诊断虚拟化网络故障诊断精度；
- 过滤异常网络状态信息，降低信息采集开销；

内容提纲



■ 研究背景

■ 研究目标

■ 研究成果

■ 原型系统

■ 总结展望

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



- ❑ **核心问题**：如何采集充足的信息刻画虚拟化网络通信画像，构建基于租户画像的网络故障感知模型，在不影响诊断精度的前提下降低信息采集开销

现有研究工作：

- CPU、内存、磁盘资源使用率




存在的问题：**信息采集不充分**

- 资源竞争种类
- 部分资源竞争难以采集与监控



现有研究工作采集的信息难以充分刻画虚拟化网络故障



- ❑ **解决思路**：根据文献资料与实验定义虚拟化网络信息采集目标

- ❑ **核心子问题1**：如何分析虚拟化网络故障种类以及故障原因并确定信息采集目标？

- ❑ **核心子问题2**：如何实现构建精确的故障感知模型降低信息采集开销？

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



□ 数据中心虚拟化网络故障分析与信息采集：

虚拟化网络故障类别：

- 可达性故障
- 性能故障

可达性故障：

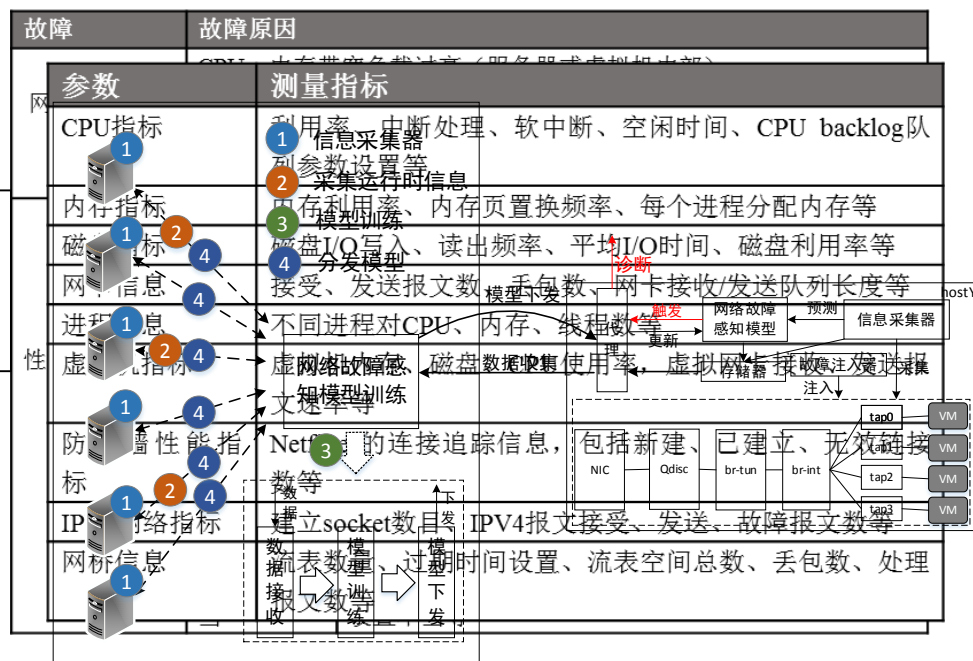
- 虚拟设备宕机
- 资源竞争

性能故障：

- 资源竞争
- 虚拟设备配置不当

信息采集目标：**租户画像**

- 服务器环境信息
- 虚拟设备参数配置信息
- 虚拟机运行信息



- 预采集：2414维度
- 采集的信息：1028维度

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



□ 基于机器学习的故障感知模型训练：

① 数据预处理


异常值与缺失值处理：删除异常样本

- 注入资源竞争故障时，信息采集器无法获得有效的CPU资源导致数值异常或缺失
- 虚拟机迁移或操作系统内部进程运行导致部分指标存在缺失

② 模型训练

模型选择与数据构建

- 充分比较多种分类算法的优劣：随机树、决策树、随机森林、朴素贝叶斯、贝叶斯网络
- 训练数据集与测试数据集产生：十折交叉验证
- 测试指标：整体的识别精度、异常信息查全率、正常信息查准率



故障信息查全率、正常信息查准率

- 故障信息的查全率直接决定了故障诊断精度
- 正常信息的查准率决定了对信息的过滤程度

直接用机器学习方法训练模型存在**故障信息查全率、正常信息查准率低**的问题

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



□ 面向故障感知模型的内存使用开销与精度的优化：

基于故障感知的信息采集：

1. 模型训练与下发
2. 信息采集服务器识别异常信息
3. 数据传输与诊断



存在的问题：

- 信息采集服务器存在内存使用限制
- 故障感知模型直接影响诊断模型的故障诊断精度，需要提高故障信息查全率
- 提高正常信息查准率，尽可能过滤正常状态信息，降低信息采集开销

本文的约束条件：

$$\begin{cases} R(F(X)) > \theta \\ \text{size}(F(X)) < L \end{cases}$$

公式解释：

- $F(X)$ 为训练的故障感知模型
- $R(X)$ 表示模型对异常信息查全率
- $\text{size}(X)$ 表示模型的存储空间

本文的优化目标：

$$\text{maximize } P(F(X))$$

公式解释：

- $P(X)$ 为模型对正常信息查准率

在满足资源限制以及对异常信息的高识别精度下，最大化降低信息采集开销

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



□ 问题分析与求解：

信息化网络状态信息特点：

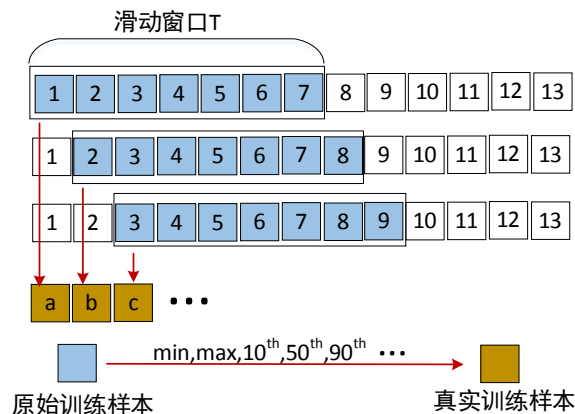
- 高维度、数值连续（1028维）
- 部分信息具有关联性
 - 直连设备发出报文数与接收报文数相等
- 网络状态在时间序列上具有关联性



解决方案：

- PCA降维，去除无关参数，降低模型复杂度
- 构建基于时间序列的网络信息特征，提高数据精度

- PCA数据降维
 - 协方差矩阵求解特征值
 - 用特征值表示参数的重要性
 - 满足损失度 γ ： $\frac{\sum_{i=1}^k p_i}{\sum_{i=1}^N p_i} > 1 - \gamma$
 - 降维数据集： $Y = PX$
- 基于滑动窗口的时间序列特征构建



<最大值，最小值，当前值，平均值，方差，第10th数值，第50th数值，第90th数值>

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



实验分析

□ 实验方案：使用故障注入方法采集训练样本，使用时间序列特征构建算法以及机器学习方法训练故障感知模型

实验平台硬件配置

硬件	硬件配置
操作系统	Centos7 内核：4.4.0
CPU	CPU：12；cores：72 intel 2.67GHz
内存	23G
磁盘	160G

实验平台部署环境

名称	指标
平台	OpenStack平台queens版本
数据集	Wiki开源PageRank数据集7个G
应用	Hadoop 2.9.3，Spark 2.3.3
运行应用	PageRank、WordCount
硬件配置	见表3-6

注入的故障列表

故障名	注入方式
网卡缓存资源竞争	设置不同网卡接收/发送队列大小，同时用大量小报文通信占满缓存队列
丢包、延迟	Qdisc模型，丢包率：1%，5%，10%；延迟：100ms±50ms
流表丢包	主动设置discard丢包；使用ovs-dpctl、ovs-ofctl设置流表总数上限、流表过期时间，同时添加大量新流表项
CPU、内存、磁盘、内存带宽资源竞争	Stress工具模拟CPU竞争75%,80%,85%；Stress工具模拟磁盘负载；MBW模拟内存拷贝负载；




训练样本采集：

- 真实环境模拟：CPU利用率75%、12个内存拷贝进程、12个I/O磁盘访问进程、httpperf模拟WEB服务
- 10G数据，55216条正常样本，53574条异常样本

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



□ 主成分分析方法对基于决策树的故障感知模型精度与开销的影响：



实验结果分析：




- PCA降维可以提高感知模型的精度，但随着特征数减少数据精度损失变多，故障感知模型精度下降
- 特征数减少可以有效缩短模型训练时间
- 模型的内存使用开销随着特征数减少先增加后减小，模型构建过程中增加树高与分支数量可以进一步提高模型精度

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



□ 基于滑动窗口的时间序列特征构建方法对模型精度的影响：

- 特征数样本为82的数据作为训练样本集
- 将时间序列特征添加到训练样本集中
- 使用不同的机器学习算法构建故障感知模型






实验结果分析：

- 基于时间序列的特征构建方法可以有效提高数据精度，对整体提高模型精度都有提升
- 决策树在整体的精度、故障信息查全率、正常信息查准率方面高，符合本文的优化目标

研究成果（1）：基于租户画像的虚拟化网络故障感知机制



故障感知模型的使用效果：



实验结果分析：

- 随着正常样本比例增加，信息采集开销快速下降，在信息比例为10:1时，信息采集开销降低了74.2%，过滤的信息中异常样本比例为1.6%，本章节提出的方法可以有效降低信息采集开销
- 信息采集器运行需要使用0.17%的CPU资源，故障感知模块运行需要0.39%的CPU资源，信息采集器需要使用60MB的内存使用开销，故障感知模型需要426MB的内存使用开销
- 本文提出的故障感知模型可以在较小的资源限制下，降低信息采集开销

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



❑ 核心问题：如何针对虚拟化网络中存在大量表征相似的故障，提供精确的root-cause级别故障诊断

虚拟化网络故障：

- 数量多（网络状态频繁改变）
- 具有大量的故障表征相似（共享服务器资源）
- 与参数配置有关





存在的问题：

- 信息难以采集——数据采集种类缺失、质量低
- 模型难以设计——root-cause级别诊断实现难度大

Resource in Shortage	Packet Drop Location
CPU	TUN (aggregated)
Memory Space	pNIC Driver
Memory Bandwidth	TUN (aggregated)
Incoming Bandwidth	pNIC
Outgoing Bandwidth	Backlog Enqueue
pCPU Backlog	Backlog Enqueue
VM Bottleneck (CPU or Bandwidth)	TUN (individual)

现有研究工作特点：

- 信息采集粗糙
- 难以定位故障



❑ 解决思路：根据虚拟化网络特点设计基于强化学习的故障诊断模型

❑ 核心子问题1：如何根据强化学习模型特点对虚拟化网络故障诊断过程建模？

❑ 核心子问题2：如何合理构建网络状态空间，提高模型诊断精度？

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



基于强化学习的虚拟化网络故障诊断模型：

① 模型选择与构建

模型选择：

- 强化学习目前处于探索阶段
- 可解释性与可操作性
- Q-learning算法

强化学习建模步骤

- 真实环境建模
- 执行动作集合设置
- 动作策略设计
- 奖励函数设计

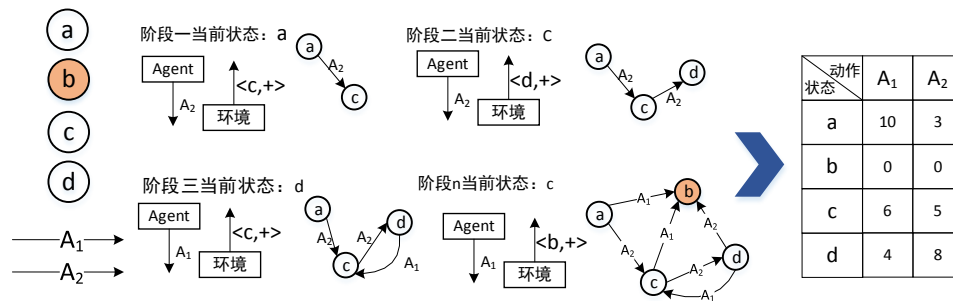
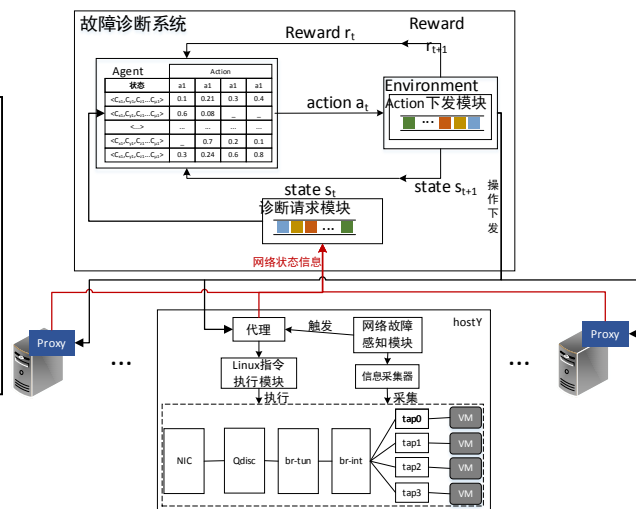
② 模型训练

强化学习模型训练目标

- 在任意状态通过查表完成故障诊断
- 右侧的表格：在任意状态下选择动作的期望收益

强化学习训练流程：

- 故障感知模型识别异常
- 诊断模型根据异常选择动作下发与验证
- 根据反馈调整记忆
- 重复上述过程



网络状态划分目标： $\forall S_E \in S, \exists! A_k \subseteq A, Edge(S_E, A_k, S_H)$

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



基于强化学习的虚拟化网络故障诊断模型构建：


真实环境建模：

- 使用租户画像刻画虚拟化网络状态



执行动作集合设置

- 故障解决方案分析
- 基于实验结果选择动作



研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



□ 基于强化学习的虚拟化网络故障诊断模型构建：

真实环境建模：

- 使用租户画像刻画虚拟化网络状态



执行动作集合设置

- 故障解决方案分析
- 基于实验结果选择动作



动作选择策略设计：

- ϵ -greedy探索策略



奖励函数设计：回合更新

- 故障间状态转换奖励为0
- 故障到正常转换奖励为R

强化学习特征取值范围：

$$\langle \min, \max \rangle = (\langle a_1, b_1 \rangle, \langle a_2, b_2 \rangle, \dots, \langle a_d, b_d \rangle)$$

以等间距划分：radius = $\langle r_1, r_2, \dots, r_d \rangle$

$$\text{网络状态空间： } S = (S_0, S_1, \dots, S_K), K = \prod_{i=1}^d \left\lfloor \frac{b_i - a_i}{r_i} \right\rfloor$$

平衡动作执行空间的探索与利用：

$$\pi(s) = \begin{cases} \text{random action from } A(s) & \text{if } \vartheta < \varepsilon \\ \max Q(s, a) & \text{otherwise} \end{cases}$$

回合更新：

- 难以通过状态改变量评估故障影响程度
- 每一轮故障完全诊断结束后，进行记忆的更新
- 对于诊断过程 $D = \langle S_0, a_0, S_1, a_1, S_2, \dots, S_{n-1}, a_{n-1}, S_H \rangle$

Q值更新：

$$\begin{cases} Q_k(s_k, a_k) = (1 - \alpha) * Q_k + \alpha * \gamma * \max Q(s_{k+1}, a_{k+1}) \\ Q_{n-1}(S_{n-1}, a_{n-1}) = (1 - \alpha) * Q_{n-1} + \alpha * R \end{cases}$$

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



□ 网络状态空间划分与优化

网络状态空间内存使用开销与精度：

- 特征数25，Q值一个字节，动作为20个，每个划分成2个，需要640MB内存进行保存
- 网络状态空间划分粒度粗导致一个状态中可能存在多个故障，导致故障诊断精度低



问题分析：

- 网络空间中大多数是正常网络状态
- 对存在多个故障的状态进一步划分，提高划分纯度



问题求解：

- 识别多故障的状态
- 状态划分条件
- 基于信息增益的网络状态空间划分

优化目标：

内存使用约束： $d * S \leq L$

网络状态划分精度： $maximize Precision(Model)$

网络状态划分目标： $\forall S_k \in S, P(Err(S_k) > 1) < \vartheta$

$\forall S_E \in S, \exists! A_k \subseteq A, Edge(S_E, A_k, S_H)$

多故障判断条件：

最优动作取极限时： $\lim_{n \rightarrow \infty} Q_k^n = \lim_{n \rightarrow \infty} R(1 - (1 - \alpha)^n) = R$

非最优动作： $\lim_{n \rightarrow \infty} Q_{k,L}^n = \gamma R$

对于非最优划分G： $Q_L = \langle R, R, \dots, R, \gamma R, \gamma R, \dots, \gamma R \rangle$

训练过程中统计： $T = (X, a_t), \quad X = (x_1, x_2, \dots, x_d)$

样本数量： $C = (c_e^1, c_e^2, \dots, c_e^m)$

分裂条件： $M = \sum_{i=1}^m c_e^i < Q$ 或 $\exists P_{c_e^k} \geq \vartheta, (i = 1, 2, \dots, m)$

$P_{c_e^i} = \frac{c_e^i}{\sum_{i=1}^m c_e^i} (i = 1, 2, \dots, m)$

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



实验分析

□ 实验环境：

- ✓ 平台实验：东南大学云计算中心提供的物理机集群，在3个节点上部署了系统，每个计算节点拥有24GB内存和12个CPU

□ 性能衡量指标：

- ✓ 网络故障诊断精度：网络故障诊断系统对故障的诊断精度
- ✓ 网络故障诊断系统使用开销：虚拟化网络故障诊断系统运行过程对CPU、内存的开销




□ 实验分组：

- ✓ 基于信息增益的网络状态空间构建方法对模型的精度与开销的影响
- ✓ 基于强化学习故障诊断模型的诊断精度
- ✓ 故障诊断模型的使用开销与模型参数设置

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



□ 基于信息增益的网络状态空间构建方法对模型的精度与开销的影响：



实验结果分析：



- 随着可用内存的增加，网络空间中的状态数量增加，模型的精度也有提升，但是随着内存的进一步增加，网络状态空间数量增长减缓，模型的精度与训练时间的增长减缓
- 提高网络空间的划分纯度可以提高模型的精度

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



□ 基于强化学习的故障诊断模型的诊断精度：

- 内存为350MB训练的故障诊断模型作为求解目标
- 使用决策树训练的故障诊断模型作为baseline





实验结果分析：

- 总体来说基于强化学习的故障诊断模型可以有效提高故障诊断精度
- 对于不同的故障的诊断精度也有较大的提升

研究成果（2）：基于强化学习的虚拟化网络故障诊断机制



□ 故障诊断模型的使用开销：



实验结果分析：

- 在不同的故障诊断请求频率下，故障诊断模型对CPU的开销较小
- 在故障请求频率为1000时，故障诊断模型使用过程中大概需要1020MB的内存，内存使用开销较小（包括Tomcat、JVM等）

内容提纲



- 研究背景

- 研究目标

- 研究成果

- 原型系统

- 总结展望

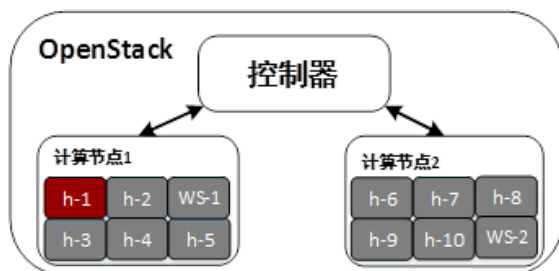
在东南大学数据中心的三台服务器上搭建了实验平台验证本文提出的研究工作的正确性

□ 硬件环境与软件部署：

硬件	硬件配置
操作系统	Centos7 内核：4.4.0
CPU	CPU：12；cores：72 intel 2.67GHz
内存	23G
磁盘	160G

名称	指标
平台	OpenStack平台queens版本
数据集	Wiki开源PageRank数据集7个G
测试应用与版本	Hadoop 2.9.3， Spark 2.3.3
运行应用	PageRank、WordCount

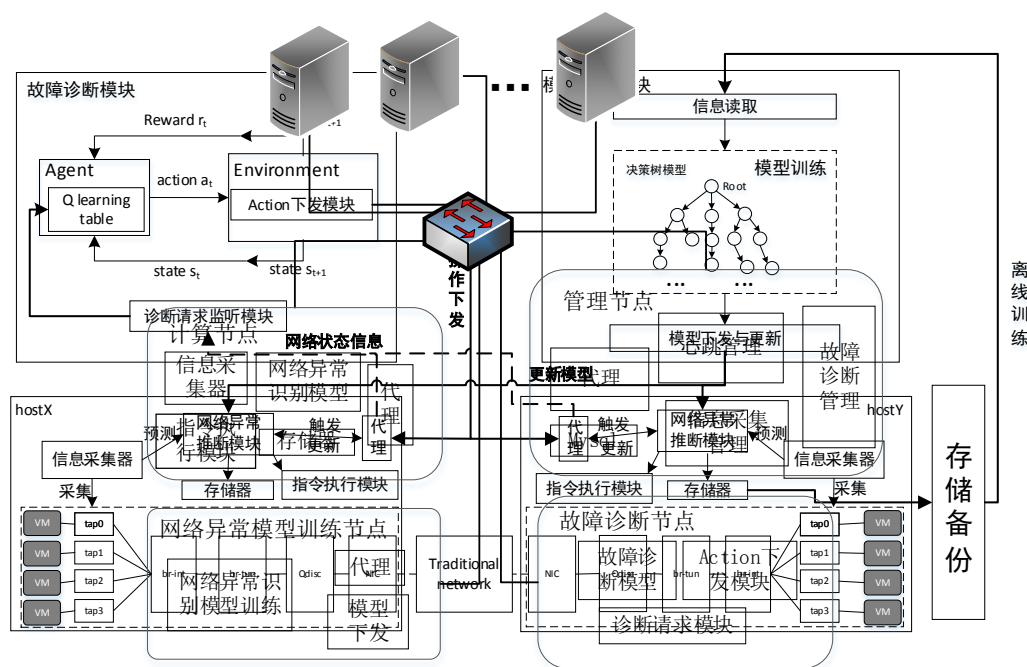
□ OpenStack中虚拟机部署：



在上述环境中将虚拟化网络故障诊断系统中的各模块进行部署，测试与验证本文研究工作的正确性与有效性

基于机器学习的虚拟化网络故障诊断系统

□ 系统整体架构图：



① 基于租户画像的信息采集模块

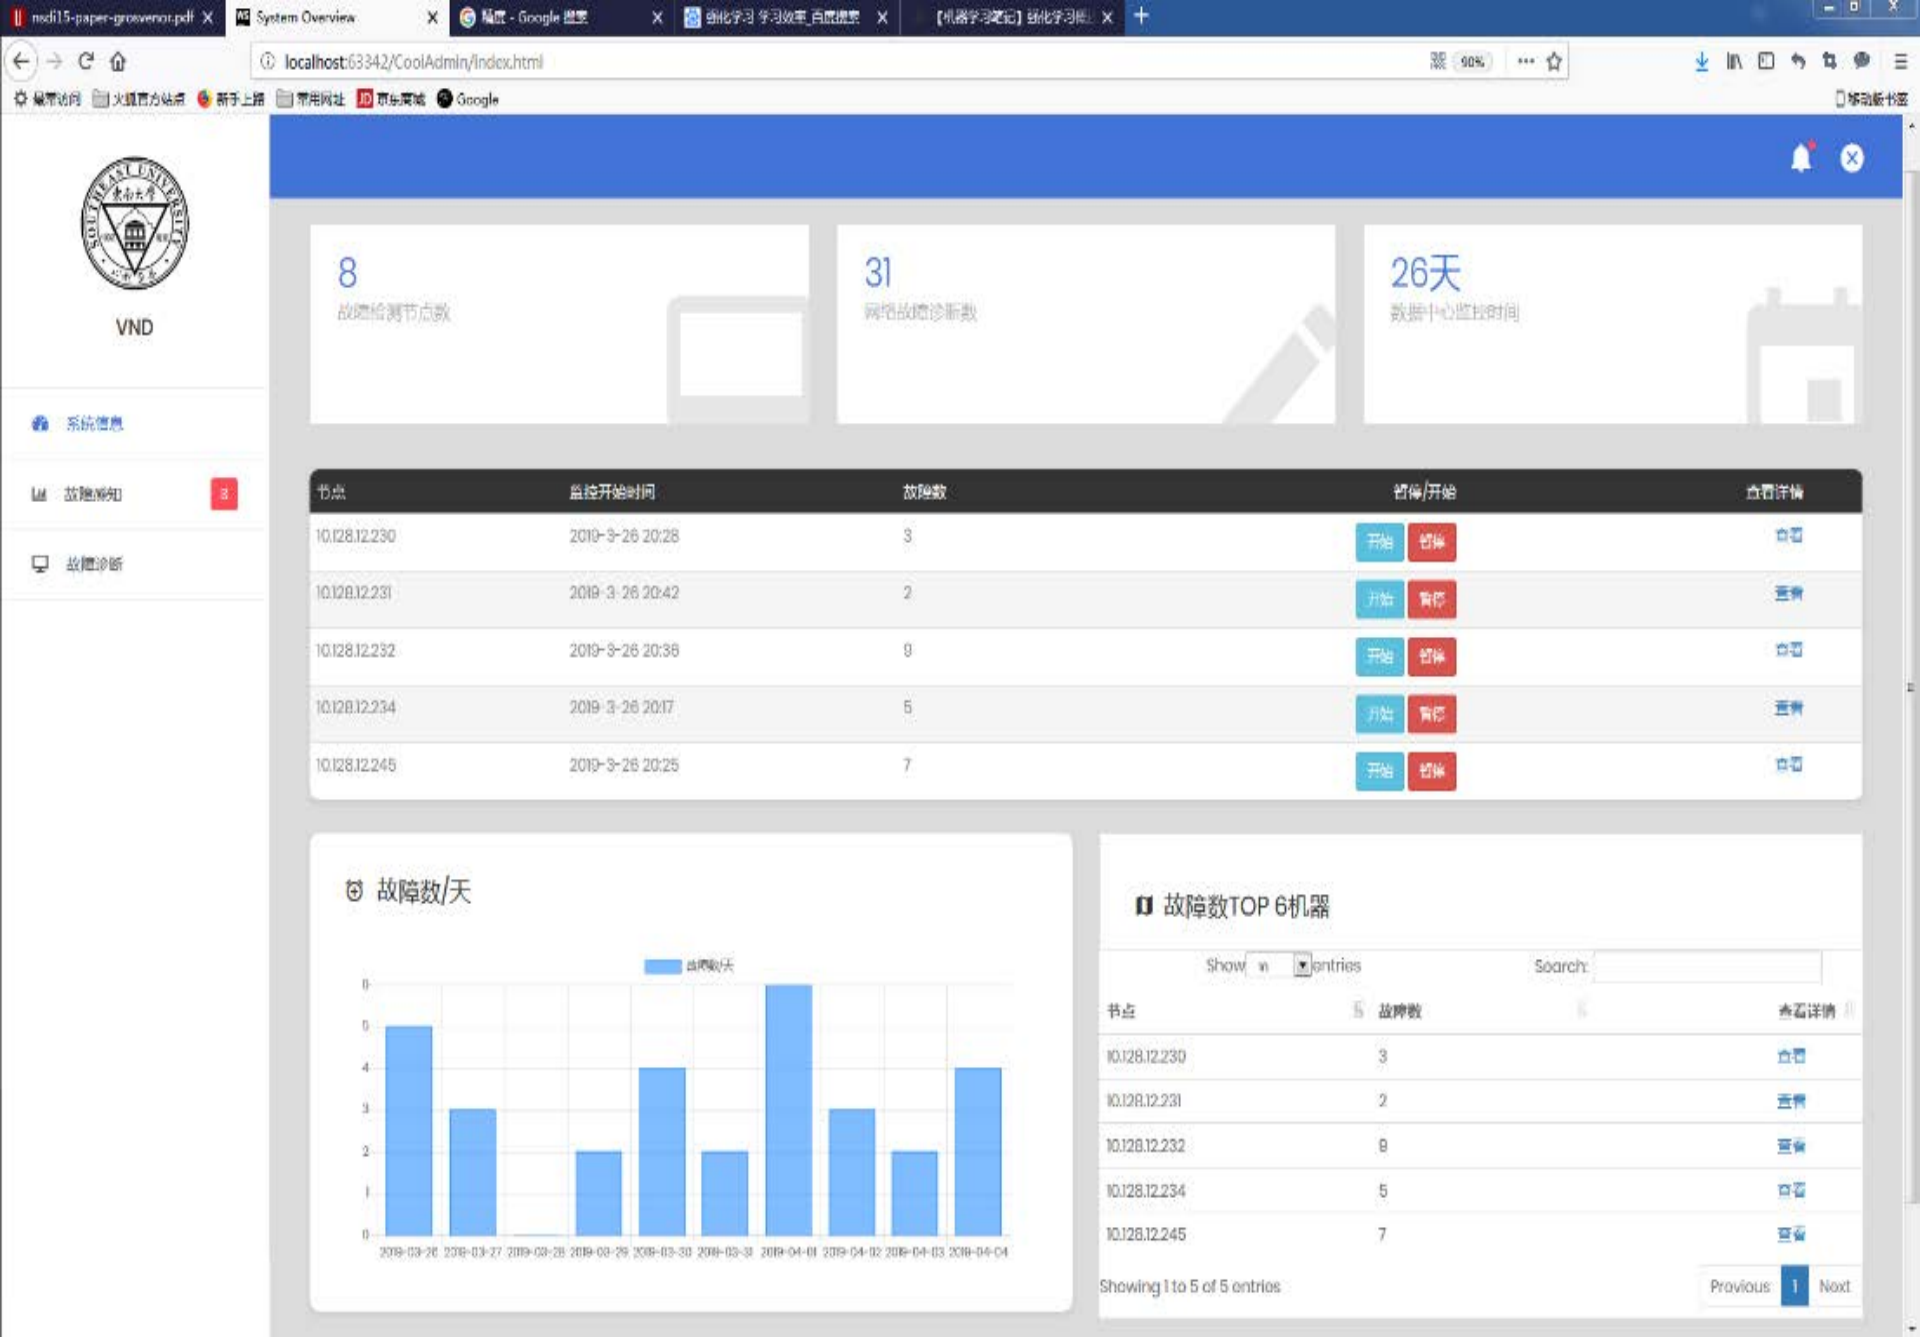
- 基于租户画像的网络故障感知模型的训练与使用。在信息采集过程中使用感知模型，通过识别异常信息，过滤正常网络状态信息，降低信息采集开销。

② 基于强化学习的故障诊断模块

- 基于强化学习的故障诊断模型的训练与使用。通过训练过程中分裂网络状态，实现提高故障诊断精度的目的。

③ 系统管理与监控模块

- 基于Java Web的系统管理平台。通过页面实现对模型训练参数的调整、查看平台规模、节点运行情况等信息





ND



节点 10.128.12.245

Id 故障

1	2019-
2	2019-
3	2019-
4	2019-
5	2019-
6	2019-4-2 09:22
7	2019-4-4 08:29

故障诊断结果



Step	Action	即时奖励	诊断结果
3	sudo ethtool -G eth0 rx 1020	-3	故障
4	Ethtool -C eth0 adaptive-rx off rx-usacs 1200 rx-frames 0	6	故障
6	sysctl -w net.core.netdev_max_backlog=1000	14	健康

确定

诊断结果查看

查看

查看

查看


查看

查看


查看

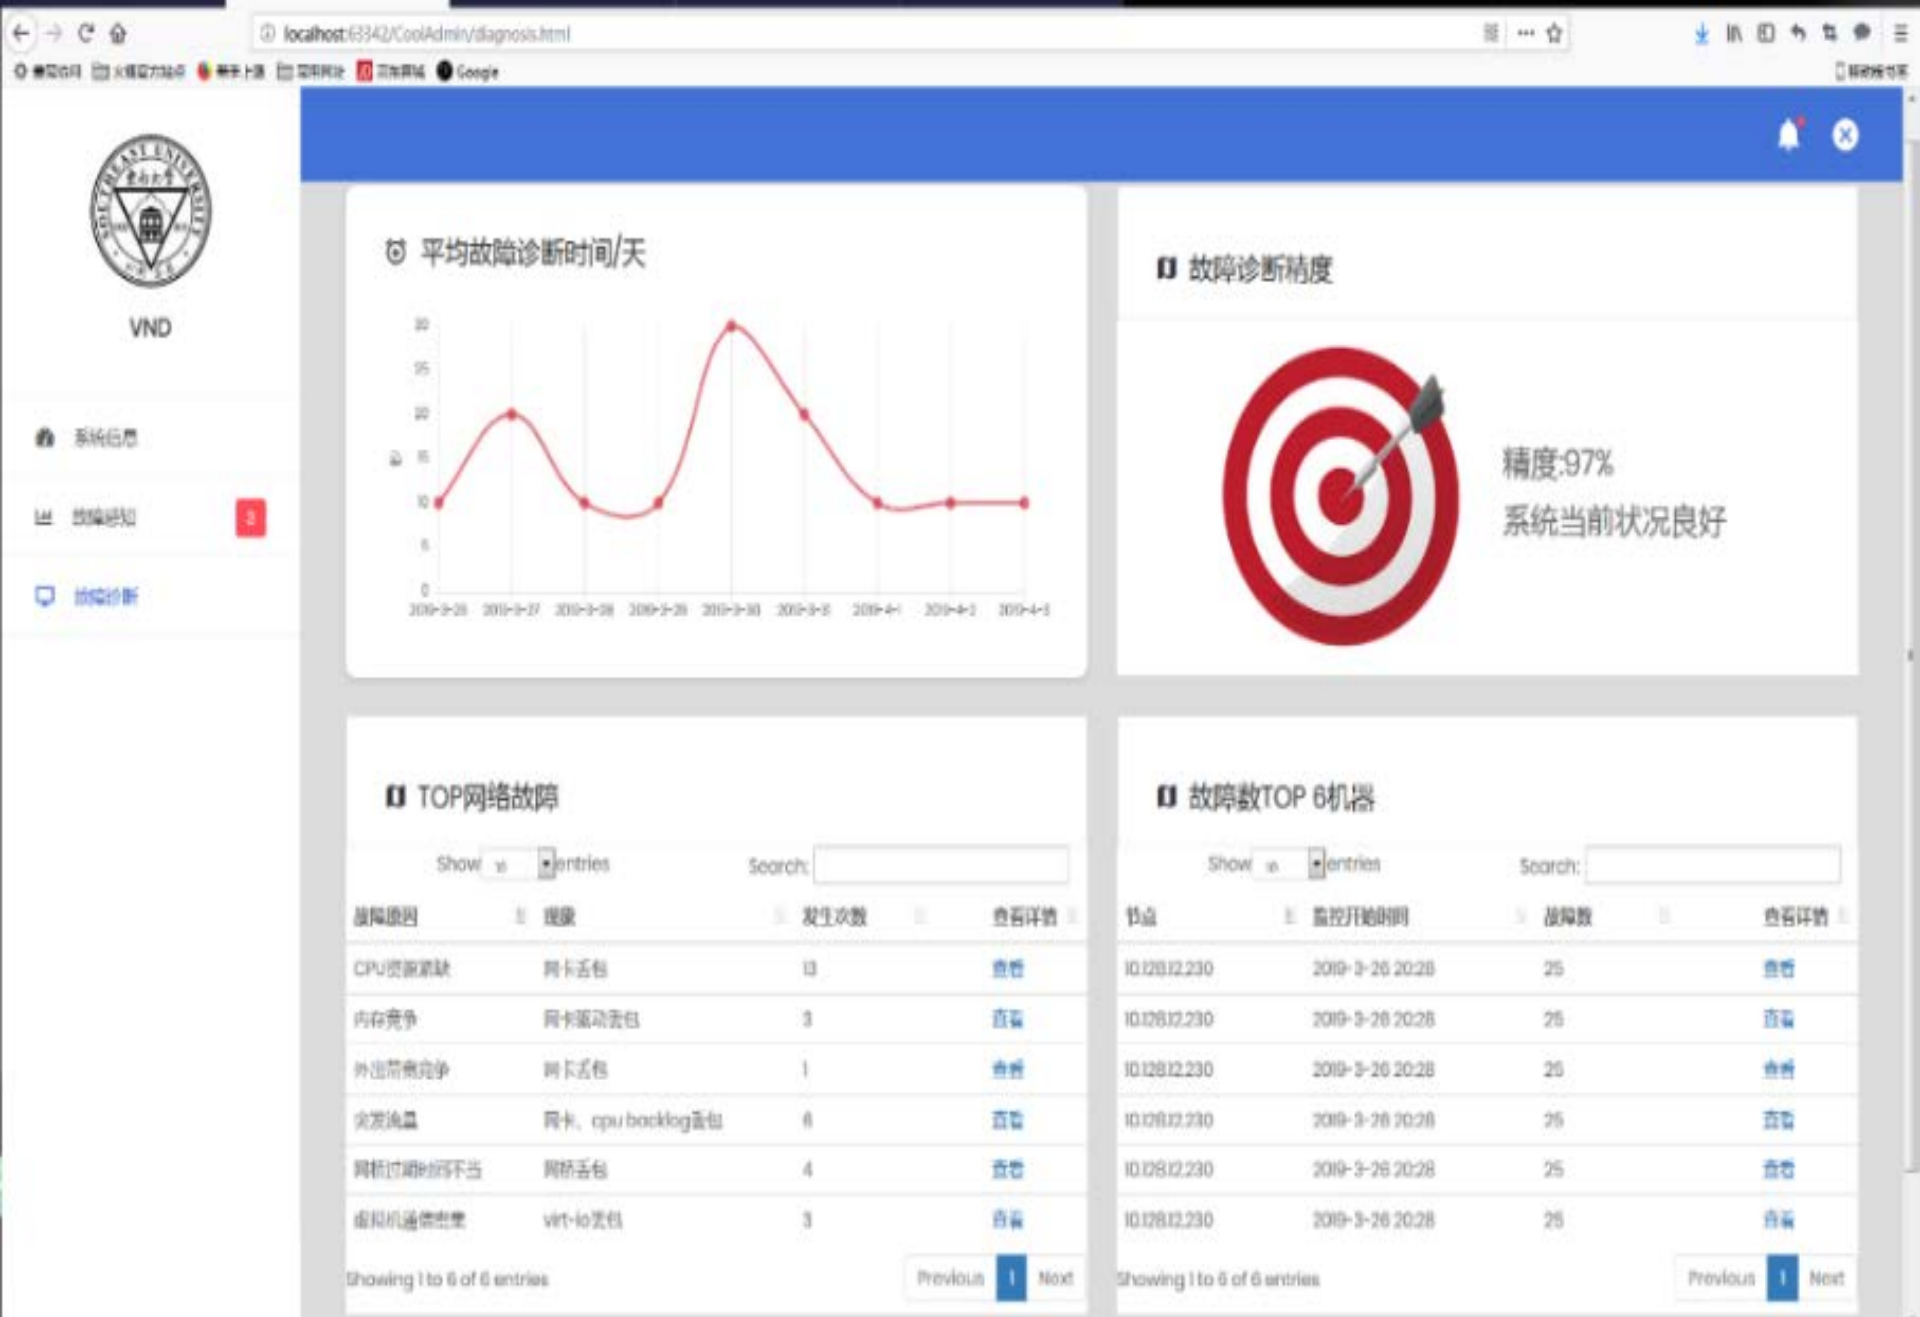
查看

故障数/天



故障诊断时间(/秒)





内容提纲



- 研究背景

- 研究目标

- 研究成果

- 原型系统

- 总结展望

工作总结



1、研究了租户画像的虚拟化网络故障诊断机制（第三章）

- ☑ 研究了虚拟化网络中租户画像的定义与设计
- ☑ 研究了基于滑动窗口的时间序列特征构建方法
- ☑ 研究了基于机器学习的网络故障感知模型构建方法

2、研究了基于强化学习的虚拟化网络故障诊断机制（第四章）

- ☑ 研究了虚拟化网络中对状态空间、动作集合、动作选择策略及奖励函数的设计
- ☑ 研究了基于信息增益的网络状态空间划分方法

3、面向数据中心的基于机器学习的虚拟化网络故障诊断系统（第五章）

- ☑ 介绍了东南大学云计算中心的硬件和应用部署情况
- ☑ 设计、实现并部署了基于机器学习的虚拟化网络故障诊断系统

1、网络故障感知机制中采集的训练数据集存在运行环境单一的问题

- ☑ 本文使用大量进程模拟服务器不同的应用负载，但是与真实的数据中心运行环境仍然存在较大的差距（频繁的虚拟机迁移与虚拟机放置），使得采集的数据不够完善，训练的模型精度难以进一步提高。

2、网络故障诊断模型中网络状态空间构建问题

- ☑ 本文虽然对Q-learning的内存使用开销与诊断精度进行了建模，并使用信息增益的方法进一步划分网络状态空间，但是实际上很多网络状态中仍然存在多个故障，影响了模型的精度，而这些问题的根因是虚拟化网络状态信息特征多、数值连续导致，未来可以考虑使用DQN进一步优化模型构建。

3、故障诊断范围进一步扩展

- ☑ 目前解决的虚拟化网络故障主要是一些常见的故障，而虚拟化网络中还存在大量交互复杂的故障，如虚拟机启动过程无法获得IP、虚拟机无法连接外网等，未来可以进一步研究与拓展系统的故障诊断范围。



谢谢！
欢迎提出宝贵意见！